AD SOYAD: SELİN ESİN KÖKÇE

NUMARA: 201713709025

Cinsiyet Sınıflandırma Projesi

Bu projemde saç uzunluğu, burun ve alın genişliği gibi yüz yapısı özelliklerini içeren dataseti kullanarak cinsiyet tahmini yaptırdım. Projemi Jupyter Notebook üzerinden python programlama dili ile geliştirdim.

Projede kullandığım veri seti: gender_classification_v7.csv

Projede kullandığım algoritmalar:
Logistic Regression, K-Nearest Neighbors (KNN), Support Vector Machine (SVM), Naive Bayes, Decision Tree (Karar Ağacı), Random Forest Classification

Bu veri seti 8 sütundan oluşmaktadır. Veri setinde 5000 satır, 8 sütun vardır ve boş değer yoktur.

long hair: Boolean özellik. Eğer saç uzun ise 1, değilse 0.
forehead_width_cm: Alın genişliğinin cm türünden ölçüsü.
forehead_height_cm: Alın uzunluğunun cm türünden ölçüsü.
nose_wide: Boolean özellik. Eğer burun geniş ise 1, ince ise 0.
nose_long: Boolean özellik. Eğer burun uzun ise 1, kısa ise 0.
lips_thin: Boolean özellik. Eğer dudak ince ise 1, kalın ise 0.
distance_nose_to_lip_long: boolean özellik. Eğer dudak ile burun arasındaki mesafe kısa ise 0, uzun ise 1.
gender: Erkek veya kadın

Not: Cm türünden değerler popülasyondaki ilgili parametrelerin ortalama hesaplamasından sonra tanımlanacaktır.

Veri setine genel bakış:

```
#Gerekli kütüphanelerin yüklenmesi.
import numpy as np
import pandas as pd

#Görselleştirme kütüphanelerinin yüklenmesi
import seaborn as sns
sns.set()
import matplotlib.pyplot as plt
from numpy import cov
```

```
#Veri setinin yüklenmesi.
person=pd.read_csv('gender_classification_v7.csv')
person
```

	long_hair	forehead_width_cm	forehead_height_cm	nose_wide	nose_long	lips_thin	distance_nose_to_lip_long	gender
0	1	11.8	6.1	1	0	1	1	Male
1	0	14.0	5.4	0	0	1	0	Female
2	0	11.8	6.3	1	1	1	1	Male
3	0	14.4	6.1	0	1	1	1	Male
4	1	13.5	5.9	0	0	0	0	Female
...	...	...	...	...	...	...	...	...
4996	1	13.6	5.1	0	0	0	0	Female
4997	1	11.9	5.4	0	0	0	0	Female
4998	1	12.9	5.7	0	0	0	0	Female
4999	1	13.2	6.2	0	0	0	0	Female
5000	1	15.4	5.4	1	1	1	1	Male

5001 rows × 8 columns

Cinsiyet

Projemde tahmin ettirmek istediğim değer cinsiyettir. Her bir cinsiyetten kaçar tane örnek olduğunu görelim.

```
person.gender.value_counts()
```

```
Female    2501
Male      2500
Name: gender, dtype: int64
```

Cinsiyete Göre Ortalama Bulma

Tahmin yaparken özelliklerin ortalama değerleri baz alınacaktır. Bu kodda ortalama değerleri iki cinsiyet için de görebiliriz:

gender	long_hair	forehead_width_cm	forehead_height_cm	nose_wide	nose_long	lips_thin	distance_nose_to_lip_long
Female	0.873251	12.811675	5.796321	0.114754	0.135946	0.121551	0.121551
Male	0.866000	13.551440	6.096360	0.873200	0.880000	0.864800	0.876400

Görselleştirme

Matplotlib kullanarak özellikleri görselleştirelim.

```
#Bar plot ile tablo olarak gösterelim:
from matplotlib.ticker import FuncFormatter

plt.figure(figsize=(20,20))
gender2=gender1.plot(kind='bar',figsize=(10,6))

for item in gender2.get_xticklabels():
    item.set_rotation(0)

plt.ylim(0.0, 14.0)
plt.legend(loc='center')
plt.title('Cinsiyete göre ortalama değer')
plt.show()
```

```
<Figure size 1440x1440 with 0 Axes>
```

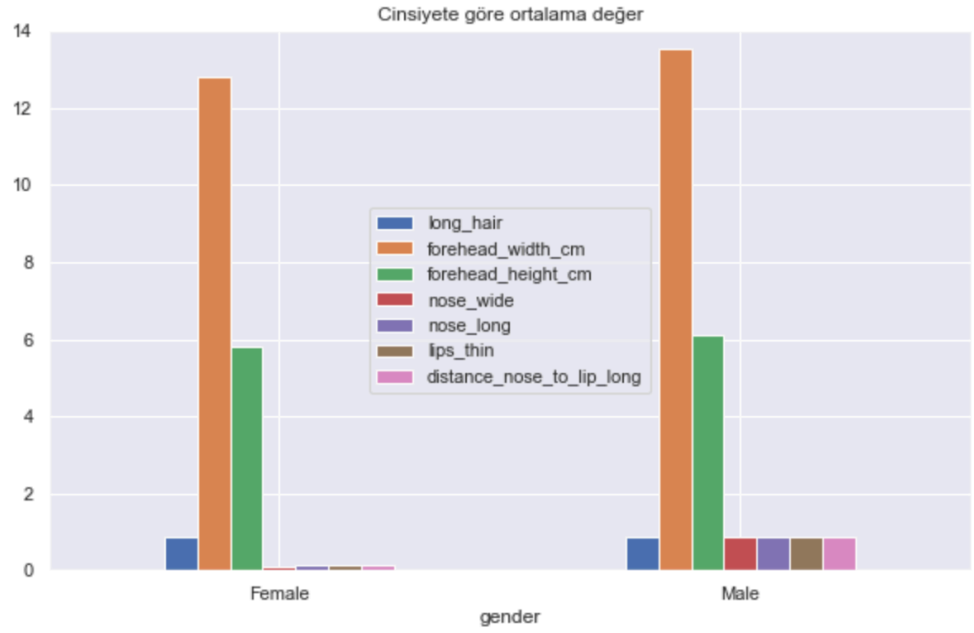

Tüm özelliklerin (saç uzunluğu hariç) erkeklerde kadınlara göre daha yüksek değerler aldığını görebiliriz. Daha detaylı incelersek:

Dudak Kalınlığının ve Dudak-Burun Mesafesinin Cinsiyete Göre Dağılımı:¶

```
person.groupby(['lips_thin','gender']).size().unstack().plot(kind='bar',figsize=(10,6))
plt.title('Cinsiyete Göre Dudak Kalınlığı')
person.groupby(['distance_nose_to_lip_long','gender']).size().unstack().plot(kind='bar',figsize=(10,6))
plt.title('Cinsiyete Göre Dudak ile Burun Arası Mesafe')
plt.show()
person.groupby(['lips_thin','gender']).size()
```

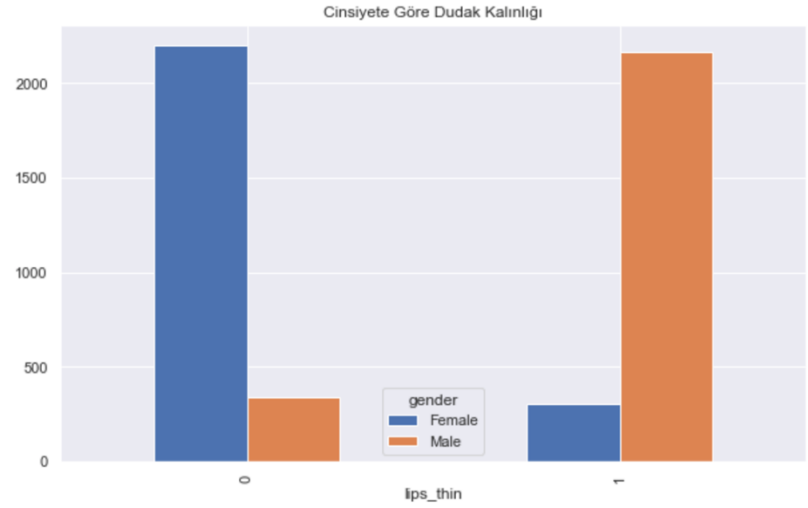

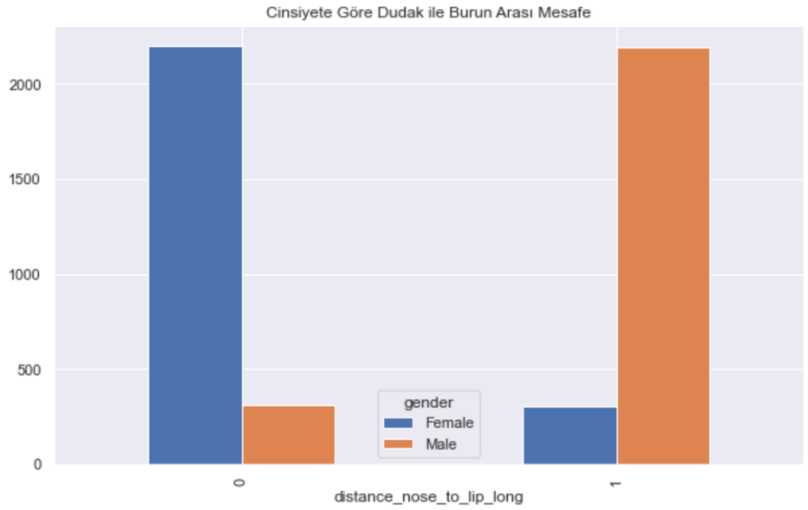


```
lips_thin  gender
0          Female    2197
           Male       338
1          Female     304
           Male      2162
dtype: int64
```

```
person.groupby(['distance_nose_to_lip_long','gender']).size()
```

```
distance_nose_to_lip_long  gender
0                          Female    2197
                           Male       309
1                          Female     304
                           Male      2191
dtype: int64
```

* **lips_thin:** Boolean özellik. Eğer dudak ince ise 1, kalın ise 0.

Tablolara bakarak kadınların erkeklere göre daha geniş dudaklara ve daha kısa burun-dudak arası mesafeye sahip olduğunu görebiliriz.

Alın Genişliği ve Uzunluğunun Cinsiyete Göre Dağılımı:

```
#Alın Genişliğinin Dağılımını Bar Plot ile Gösterelim.
sns.displot(data=person, x="forehead_width_cm", col="gender",kde=True, color='b')
```

```
<seaborn.axisgrid.FacetGrid at 0x7f8224f457f0>
```

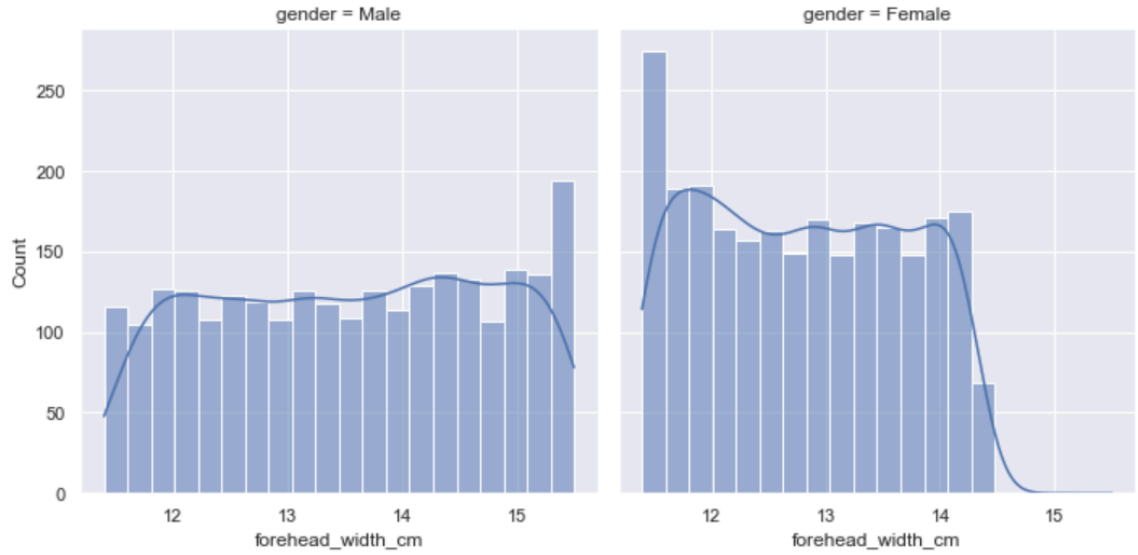


```
#Alın Uzunluğunun Dağılımını Bar Plot ile Gösterelim.
sns.displot(data=person, x="forehead_height_cm", col="gender",kde=True, color='r' )
```

```
<seaborn.axisgrid.FacetGrid at 0x7f8224d49a90>
```

- Erkeklerin kadınlara göre daha geniş ve uzun alına sahip olduğunu görebiliriz.

Saç Uzunluğunun Cinsiyete Göre Dağılımı:

```
person.groupby(['long_hair','gender']).size().unstack().plot(kind='bar',figsize=(10,6))

plt.title('Cinsiyete Göre Saç Uzunluğu')
plt.show()
person.groupby(['long_hair','gender']).size()
```

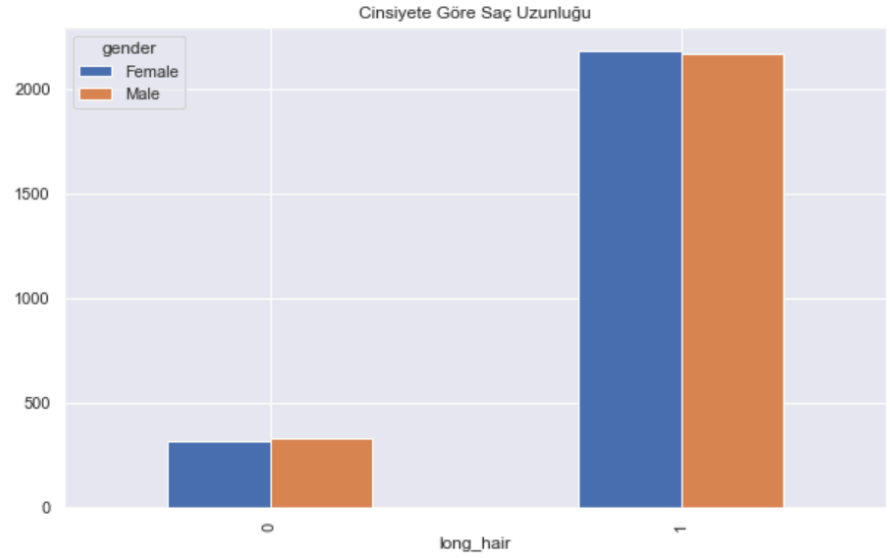


```
long_hair  gender
0          Female     317
           Male       335
1          Female    2184
           Male      2165
dtype: int64
```

- Kadınlar ile erkekler arasında saç uzunluğu dağılımının neredeyse aynı olduğunu görebiliriz.

Burun Genişliği ve Uzunluğunun Cinsiyete Göre Dağılımı:

```
person.groupby(['nose_wide','gender']).size().unstack().plot(kind='bar',figsize=(10,6))
plt.title('Burun Genişliğinin Cinsiyete Göre Dağılımı')
plt.show()
person.groupby(['nose_wide','gender']).size()
```

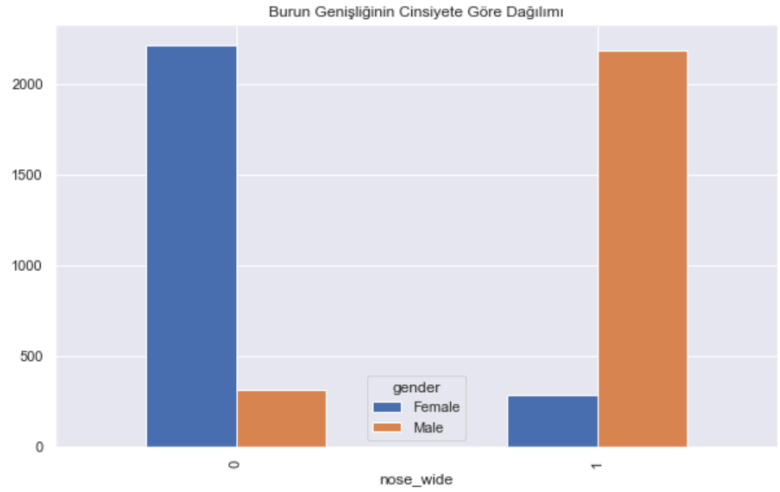


```
nose_wide  gender
0          Female    2214
           Male       317
1          Female     287
           Male      2183
dtype: int64
```

```
person.groupby(['nose_long','gender']).size().unstack().plot(kind='bar',figsize=(10,6))
plt.title('Burun Uzunluğunun Cinsiyete Göre Dağılımı')
plt.show()
person.groupby(['nose_long','gender']).size()
```

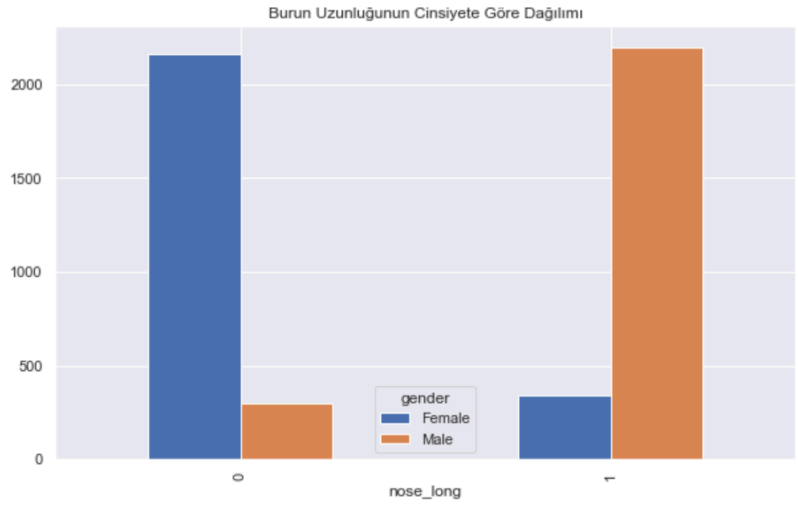


```
nose_long  gender
0          Female    2161
           Male       300
1          Female     340
           Male      2200
dtype: int64
```

- Kadınların erkeklere göre daha ince ve kısa buruna sahip olduğunu görebiliriz.

Veri setinde 'gender' özelliği string türündedir. Float değerine de ihtiyacımız olacağından 'gender_code' sütunu ekledim. Erkekler için 0, kadınlar için 1 değerini verdim.

```
person['gender_code']=pd.factorize(person.gender)[0]
person.head()
```

	long_hair	forehead_width_cm	forehead_height_cm	nose_wide	nose_long	lips_thin	distance_nose_to_lip_long	gender	gender_code
0	1	11.8	6.1	1	0	1	1	Male	0
1	0	14.0	5.4	0	0	1	0	Female	1
2	0	11.8	6.3	1	1	1	1	Male	0
3	0	14.4	6.1	0	1	1	1	Male	0
4	1	13.5	5.9	0	0	0	0	Female	1

Train Test Split (Eğitim/Test Seti Ayırma)

```
y = person.gender_code.values

x = person[["long_hair","forehead_width_cm","forehead_height_cm",
          "nose_wide","nose_long","lips_thin","distance_nose_to_lip_long"]].values
```

```
from sklearn.model_selection import train_test_split
#veriyi eğitim ve test seti olarak ayırıyoruz:

x_train, x_test, y_train, y_test = train_test_split(x, y, test_size = 0.2, random_state = 42)

x_train = x_train.T
x_test = x_test.T
y_train = y_train.T
y_test = y_test.T

print("x_train : ",x_train)
print("x_test : ",x_test)
print("y_train : ",y_train)
print("y_test : ",y_test)
```

```
x_train :  [[ 1.   1.   0.  ...  1.   1.   1. ]
 [15.4 12.2 11.5 ... 12.  12.8 11.4]
 [ 6.6  5.2  5.8 ...  5.9  5.4  5.5]
 ...
 [ 1.   0.   0.  ...  0.   0.   0. ]
 [ 1.   0.   0.  ...  0.   0.   0. ]
 [ 1.   0.   0.  ...  0.   0.   0. ]]
x_test :  [[ 1.   1.   0.  ...  1.   1.   1. ]
 [13.2 13.7 12.9 ... 14.3 13.9 13. ]
 [ 5.7  6.   5.3 ...  5.7  6.3  5.4]
 ...
 [ 1.   0.   0.  ...  0.   1.   1. ]
 [ 1.   0.   0.  ...  0.   1.   0. ]
 [ 1.   0.   1.  ...  0.   1.   1. ]]
y_train :  [0 1 1 ... 1 1 1]
y_test :  [0 1 1 ... 1 0 1]
```

Logistic Regression

```
from sklearn.model_selection import train_test_split
x_test, x_train, y_test, y_train = train_test_split(x, y, test_size = 0.15, random_state = 42)
from sklearn import linear_model

logreg = linear_model.LogisticRegression(random_state = 42, max_iter = 150)

print("Test Accuracy : ", (logreg.fit(x_train, y_train).score(x_test, y_test)))
print("Train Accuracy : ", (logreg.fit(x_train, y_train).score(x_train, y_train)))
```

```
Test Accuracy :  0.9675294117647059
Train Accuracy :  0.9707057256990679
```

Projemde kullandığım algoritmalarda ilk olarak confusion matrix'in görselleştirmesini yaptım. Accuracy, precision, recall, f1-score, support değerlerini gösterdim. Model performansını değerlendirmek için MAE, MSE, RMSE ve Kappa Score değerlerini gösterdim.

KNN Sınıflandırması

```
from sklearn.model_selection import train_test_split
from sklearn.neighbors import KNeighborsClassifier

x_train, x_test, y_train, y_test = train_test_split(x, y, test_size = 0.2, random_state = 42)
knn = KNeighborsClassifier(n_neighbors = 9)
knn.fit(x_train,y_train)

#Görselleştirme yapılması
from sklearn.metrics import confusion_matrix
import seaborn as sns
f, ax = plt.subplots(figsize = (5,5))
cm = confusion_matrix(y_test, knn.predict(x_test))
sns.heatmap(cm,annot = True, linewidth = 0.5, linecolor = "red", fmt = ".0f", ax = ax)
plt.show()

score_list = []
for each in range(1,15):
    knn2 = KNeighborsClassifier(n_neighbors = each)
    knn2.fit(x_train, y_train)
    score_list.append(knn2.score(x_test, y_test))

plt.plot(range(1,15), score_list)
plt.xlabel("k değerleri")
plt.ylabel("Accuracy")
plt.show()

y_pred = knn.predict(x_test)

from sklearn import metrics
from sklearn.metrics import classification_report, confusion_matrix

print("Accuracy: ", knn.score(x_test, y_test))
print("Confusion Matrix : ", cm)
print()
print(classification_report(y_test, y_pred))

print("KNN için Model Performansının Değerlendirilmesi")
print('MAE:', metrics.mean_absolute_error(y_test, y_pred))
print('MSE:', metrics.mean_squared_error(y_test, y_pred))
print('RMSE:', np.sqrt(metrics.mean_squared_error(y_test, y_pred)))

#kappa score hesabı
from sklearn.metrics import cohen_kappa_score
kappa_score =cohen_kappa_score(y_test,y_pred)
print("KAPPA SCORE:" ,kappa_score)
```

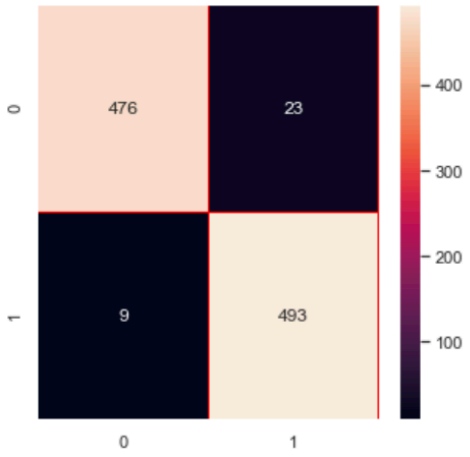

Her bir k değeri için accuracy değerini gösteren tablo:

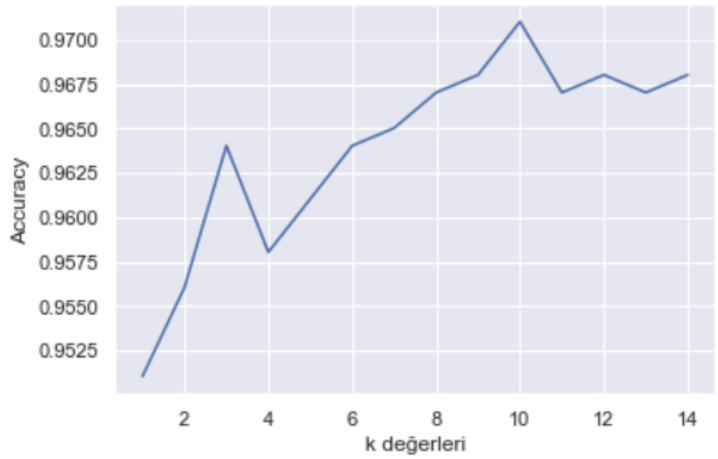

```
Accuracy:  0.968031968031968
Confusion Matrix :  [[476  23]
 [  9 493]]

              precision    recall  f1-score   support

           0       0.98      0.95      0.97       499
           1       0.96      0.98      0.97       502

    accuracy                           0.97      1001
   macro avg       0.97      0.97      0.97      1001
weighted avg       0.97      0.97      0.97      1001
```

```
KNN için Model Performansının Değerlendirilmesi
MAE: 0.03196803196803197
MSE: 0.03196803196803197
RMSE: 0.17879606250706967
KAPPA SCORE: 0.9360580013334557
```

*RMSE değerinin olabildiğince düşük olmasını isteriz. RMSE değeri düştükçe modelin tahmin yeteneği artar.

SVM (Support Vector Machine)

```
from sklearn.model_selection import train_test_split
x_train, x_test, y_train, y_test = train_test_split(x, y, test_size = 0.15, random_state = 1)

#Görselleştirme yapılması
import seaborn as sns
f, ax = plt.subplots(figsize = (5,5))
sns.heatmap(cm, annot = True, linewidth = 0.5, linecolor = "red", fmt = ".0f", ax = ax)
plt.show()

from sklearn.svm import SVC
svm = SVC(random_state = 1)
svm.fit(x_train, y_train)


from sklearn.metrics import classification_report,confusion_matrix
cm = confusion_matrix(y_test, svm.predict(x_test))
print("Accuracy: ", svm.score(x_test, y_test))
print("Confusion Matrix : ", cm)

y_pred = svm.predict(x_test)
print()
print(classification_report(y_test, y_pred))

print("SVM için Model Performansının Değerlendirilmesi")
print('MAE:', metrics.mean_absolute_error(y_test, y_pred))
print('MSE:', metrics.mean_squared_error(y_test, y_pred))
print('RMSE:', np.sqrt(metrics.mean_squared_error(y_test, y_pred)))

#kappa score hesabı
from sklearn.metrics import cohen_kappa_score
kappa_score =cohen_kappa_score(y_test,y_pred)
print("KAPPA SCORE:" ,kappa_score)
```

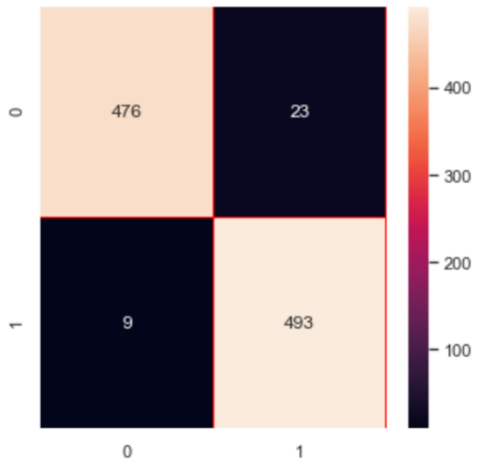

```
Accuracy:  0.9707057256990679
Confusion Matrix :  [[355  14]
 [  8 374]]

              precision    recall  f1-score   support

           0       0.98      0.96      0.97       369
           1       0.96      0.98      0.97       382

    accuracy                           0.97       751
   macro avg       0.97      0.97      0.97       751
weighted avg       0.97      0.97      0.97       751
```

```
SVM için Model Performansının Değerlendirilmesi
MAE: 0.02929427430093209
MSE: 0.02929427430093209
RMSE: 0.17115570192351784
KAPPA SCORE: 0.9413776708605653
```

Naive Bayes

```
from sklearn.model_selection import train_test_split
x_train, x_test, y_train, y_test = train_test_split(x, y, test_size = 0.3, random_state = 1)

from sklearn.naive_bayes import GaussianNB
nb = GaussianNB()
nb.fit(x_train, y_train)

from sklearn.metrics import confusion_matrix
cm = confusion_matrix(y_test, nb.predict(x_test))

#Görselleştirme yapılması
import seaborn as sns
f, ax = plt.subplots(figsize = (5,5))
sns.heatmap(cm, annot = True, linewidth = 0.5, linecolor = "red", fmt = ".0f", ax = ax)
plt.show()

print("Accuracy: ", nb.score(x_test, y_test))
print("Confusion Matrix : ", cm)

y_pred = nb.predict(x_test)

from sklearn.metrics import classification_report, confusion_matrix
print()
print(classification_report(y_test, y_pred))

print("Naive Bayes için Model Performansının Değerlendirilmesi")
print('MAE:', metrics.mean_absolute_error(y_test, y_pred))
print('MSE:', metrics.mean_squared_error(y_test, y_pred))
print('RMSE:', np.sqrt(metrics.mean_squared_error(y_test, y_pred)))

#kappa score hesabı
from sklearn.metrics import cohen_kappa_score
kappa_score =cohen_kappa_score(y_test,y_pred)
print("KAPPA SCORE:" ,kappa_score)
```

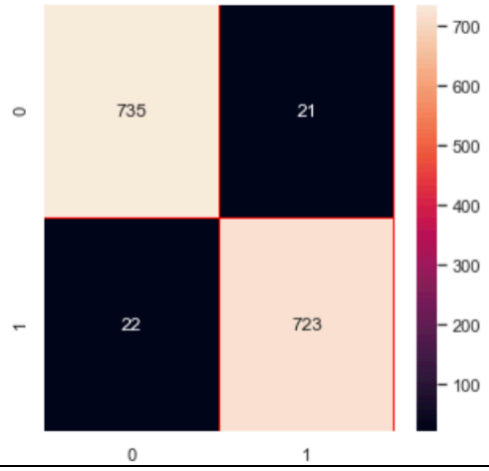

```
Accuracy:  0.9713524317121919
Confusion Matrix :  [[735  21]
 [ 22 723]]

              precision    recall  f1-score   support

           0       0.97      0.97      0.97       756
           1       0.97      0.97      0.97       745

    accuracy                           0.97      1501
   macro avg       0.97      0.97      0.97      1501
weighted avg       0.97      0.97      0.97      1501
```

```
Naive Bayes için Model Performansının Değerlendirilmesi
MAE: 0.028647568287808126
MSE: 0.028647568287808126
RMSE: 0.1692559254141731
KAPPA SCORE: 0.9427012266196981
```

Decision Tree (Karar Ağacı)

```python
from sklearn.model_selection import train_test_split
x_train, x_test, y_train, y_test = train_test_split(x, y, test_size = 0.15, random_state = 1)

from sklearn.tree import DecisionTreeClassifier
dt = DecisionTreeClassifier()
dt.fit(x_train, y_train)

#Görselleştirme yapılması
import seaborn as sns
f ,ax = plt.subplots(figsize = (5,5))
sns.heatmap(cm, annot = True, linewidth = 0.5, linecolor = "red", fmt = ".0f", ax = ax)
plt.show()

from sklearn.metrics import confusion_matrix
cm = confusion_matrix(y_test, dt.predict(x_test))
print("Accuracy: ", dt.score(x_test, y_test))
print("Confusion Matrix : ", cm)

y_pred = dt.predict(x_test)

from sklearn.metrics import classification_report, confusion_matrix
print()
print(classification_report(y_test, y_pred))

print("Desicion Tree için Model Performansının Değerlendirilmesi")
print('MAE:', metrics.mean_absolute_error(y_test, y_pred))
print('MSE:', metrics.mean_squared_error(y_test, y_pred))
print('RMSE:', np.sqrt(metrics.mean_squared_error(y_test, y_pred)))

#kappa score hesabı
from sklearn.metrics import cohen_kappa_score
kappa_score =cohen_kappa_score(y_test,y_pred)
print("KAPPA SCORE:" ,kappa_score)
```

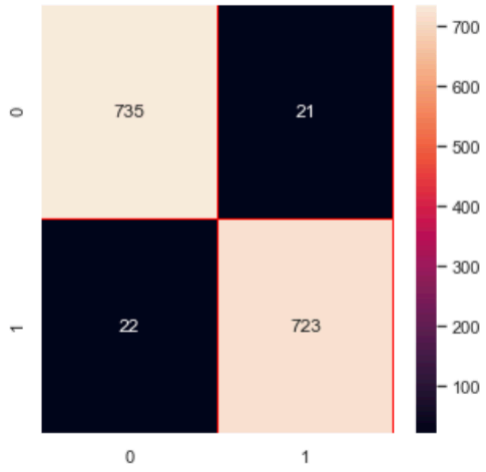

```
Accuracy:  0.9693741677762983
Confusion Matrix :  [[358  11]
 [ 12 370]]

              precision    recall  f1-score   support

           0       0.97      0.97      0.97       369
           1       0.97      0.97      0.97       382

    accuracy                           0.97       751
   macro avg       0.97      0.97      0.97       751
weighted avg       0.97      0.97      0.97       751
```

```
Desicion Tree için Model Performansının Değerlendirilmesi
MAE: 0.03062583222370173
MSE: 0.03062583222370173
RMSE: 0.1750023777658513
KAPPA SCORE: 0.9387328015209503
```

Random Forest Classification

```
from sklearn.model_selection import train_test_split
x_train, x_test, y_train, y_test = train_test_split(x, y, test_size = 0.15, random_state = 42)

from sklearn.ensemble import RandomForestClassifier
rf = RandomForestClassifier(n_estimators = 100, random_state = 1)
rf.fit(x_train, y_train)

#Görselleştirme yapılması
import seaborn as sns
f, ax = plt.subplots(figsize = (5,5))
sns.heatmap(cm, annot = True, linewidth = 0.5, linecolor = "red", fmt = ".0f", ax = ax)
plt.show()


from sklearn.metrics import confusion_matrix
cm = confusion_matrix(y_test, rf.predict(x_test))
print("Accuracy: ", rf.score(x_test, y_test))
print("Confusion Matrix : ", cm)


y_pred = rf.predict(x_test)

from sklearn.metrics import classification_report, confusion_matrix
print()
print(classification_report(y_test, y_pred))

print("Random Forest için Model Performansının Değerlendirilmesi")
print('MAE:', metrics.mean_absolute_error(y_test, y_pred))
print('MSE:', metrics.mean_squared_error(y_test, y_pred))
print('RMSE:', np.sqrt(metrics.mean_squared_error(y_test, y_pred)))

#kappa score hesabı
from sklearn.metrics import cohen_kappa_score
kappa_score =cohen_kappa_score(y_test,y_pred)
print("KAPPA SCORE:" ,kappa_score)
```

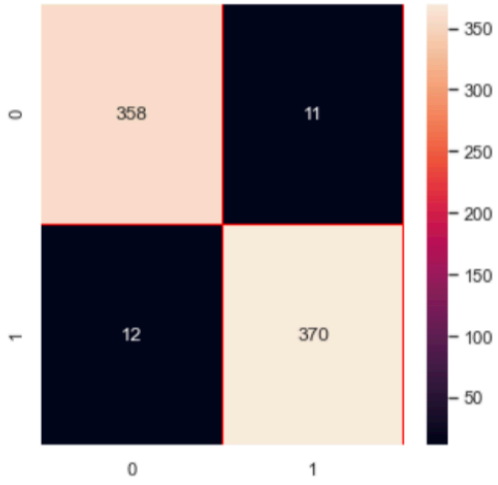

```
Accuracy:  0.966711051930759
Confusion Matrix :  [[349  13]
 [ 12 377]]

              precision    recall  f1-score   support

           0       0.97      0.96      0.97       362
           1       0.97      0.97      0.97       389

    accuracy                           0.97       751
   macro avg       0.97      0.97      0.97       751
weighted avg       0.97      0.97      0.97       751
```

```
Random Forest için Model Performansının Değerlendirilmesi
MAE: 0.033288948069241014
MSE: 0.033288948069241014
RMSE: 0.18245259129220667
KAPPA SCORE: 0.9333295455756031
```

Accuracy Değerlerinin Karşılaştırılması¶

Logistic Regression için;
Test Accuracy: 0.9675294117647059
Train Accuracy: 0.9707057256990679
KNN için Accuracy: 0.968031968031968
Support Vector Machine (SVM) için Accuracy: 0.9680426098535286
Naive Bayes için Accuracy: 0.9713524317121919
Decision Tree (Karar Ağacı) için Accuracy: 0.9693741677762983
Random Forest Classification için Accuracy: 0.966711051930759

En yüksek accuracy'nin Naive Bayes algoritması ile alındığı görülür. Naive Bayes kullanarak tahmin yaptırdığım kodlar :

Naive Bayes Algoritması ile Tahmin Ettirme¶

Değerleri hatırlayalım:

"long_hair","forehead_width_cm","forehead_height_cm",
"nose_wide","nose_long","lips_thin","distance_nose_to_lip_long"

Doğru tahmin yapıp yapmadığını kontrol edebilmek için veri setinde bulunan bir erkeğe ait değerleri girdim.

```
x_predict = [[0,14,5.4,1,1,1,1]]  #tahmin edilmesini istediğim değerleri girdim.
y_predict = nb.predict(x_predict)
```

```
#Cinsiyet tahmini(male=0, female=1):
y_predict[0]
```

```
0
```

```
#Cinsiyet tahmini:
if y_predict[0]==0:
    print("male")
elif y_predict[0]==1:
    print("female")
```

```
male
```

Girdiğim bu değerlere göre, algoritmanın cinsiyet tahmini sonucu erkek çıktı. Doğru çalışıyor.

GUI (Arayüz)

Uygulama arayüzü için Python programlama dili ile birlikte gelen grafiksel kullanıcı arayüzü aracıdır **Tkinter'i** kullandım.

Arayüzde kullanıcı girişi için entry alanları, cinsiyet tahmin butonu, istatistikleri gösteren buton, sırayla MAE,MSE,RMSE ve KAPPA'yı gösteren buton ve veri setinin genel görünümünü gösteren dataset butonu vardır.

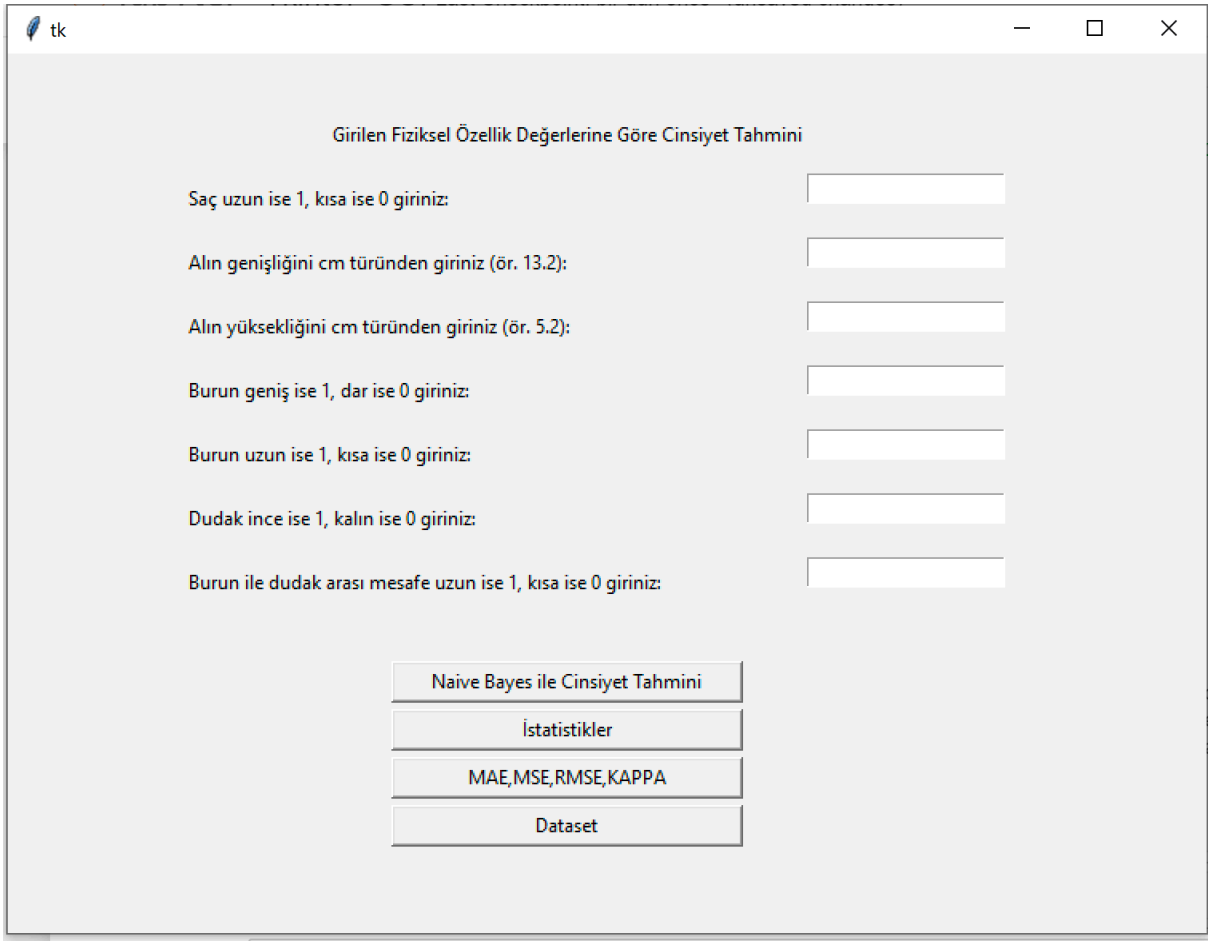

Örnek cinsiyet tahmini sonucu:

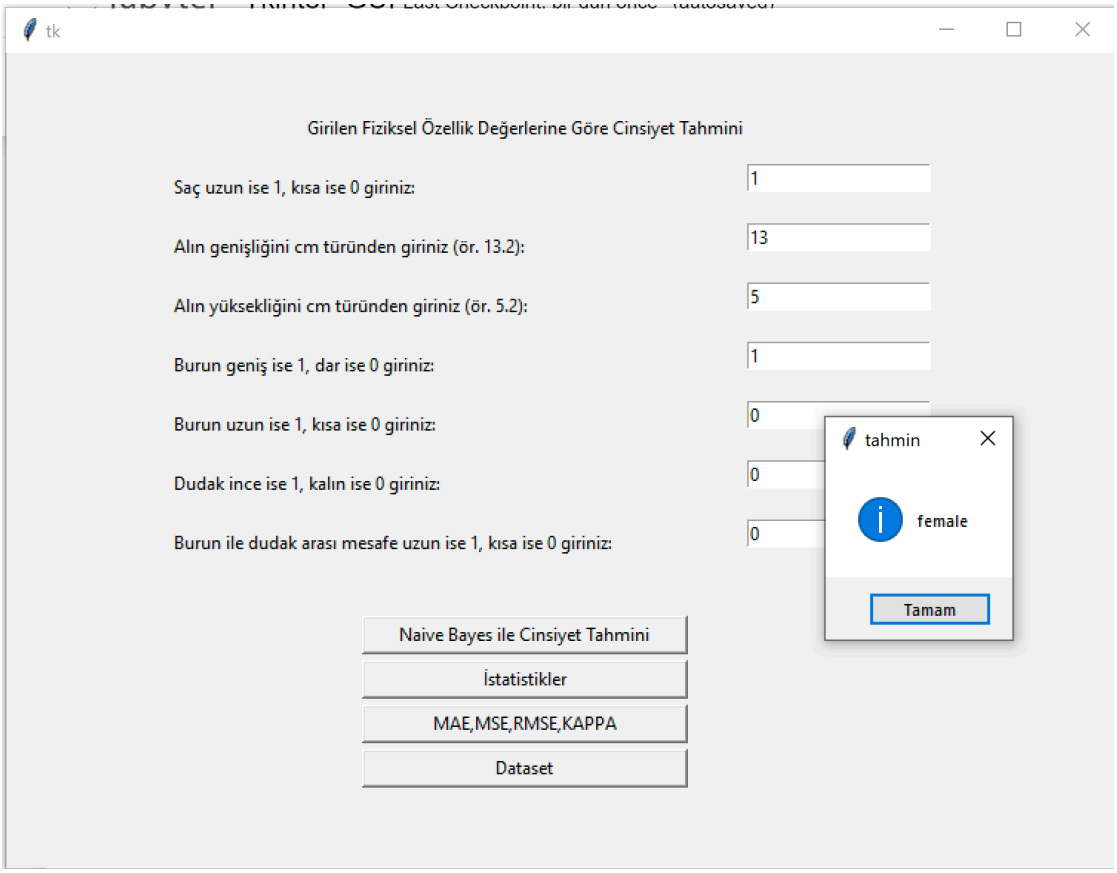

Naive Bayes istatistik sonuçları:

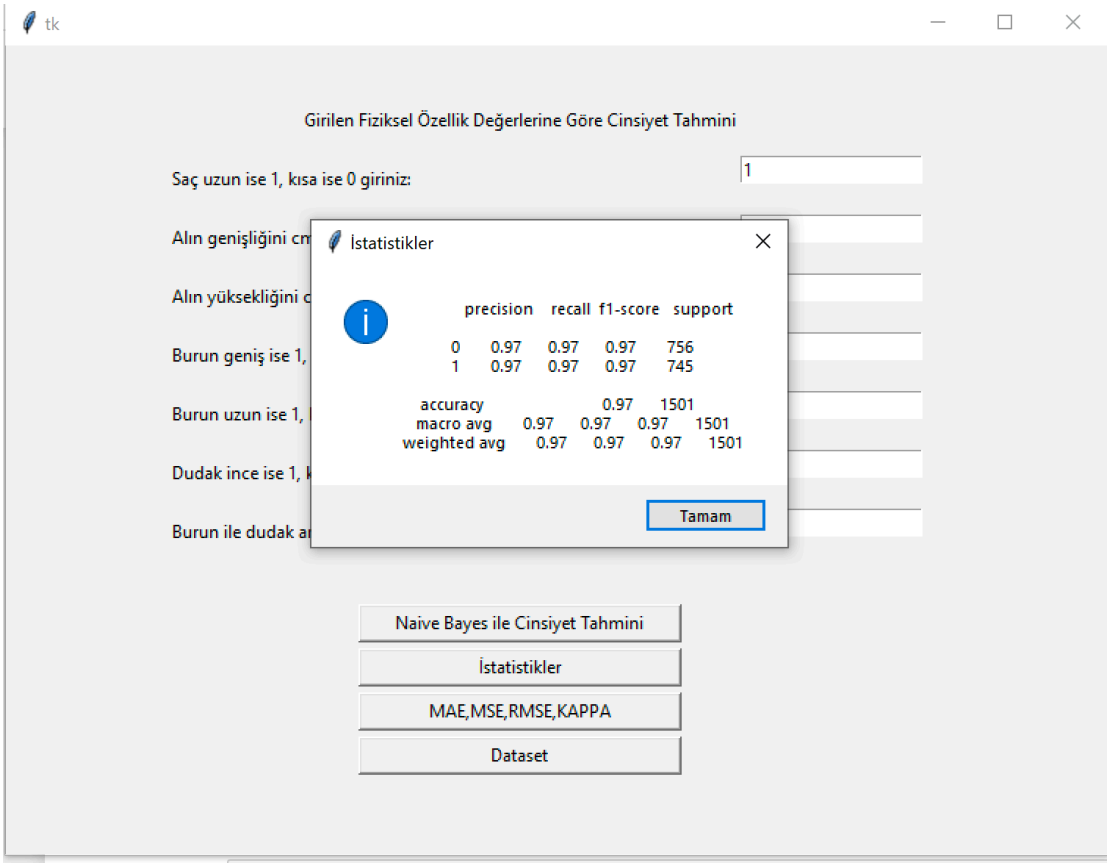

MAE, MSE, RMSE, KAPPA sonuçlarının ekranda gösterilmesi: